


Neural Collaborative Filtering

Abstract

Matrix Factorization(이하 MF)은 유저와 서비스 간의 상호 관계를 내적을 통해 표현하였다. 하지만 이 방식은 선형적인 방식이었으며 선형 모델이 가지는 한계를 갖게 된다. 본 논문에서는 내적이라는 선형 방식에 인공신경망 구조를 사용한 Neural Collaborative Filtering(이하 NCF)를 제시하여 보다 유연한 방식으로 유저와 서비스 간의 관계를 표현하였다.

Introduction

일반적으로 MF는 내적이라는 선형적인 구조이다. 하지만 이는 수백만의 유저와 수십만의 서비스의 관계를 표현하는데 너무 단순하다는 한계가 있다.이에 반해 심층 신경망(Deep Neural Network)는 비선형적인 구조로 보다 복잡한 관계를 표현하는데 용이하다.



해당 논문에서는 다음의 세 가지를 논문을 통해 주장하고 있다.


- 1.심층 신경망에 기반한 협업 필터링 방식(NCF)
- 2.MF는 NCF의 한 케이스임을 증명
- 3.다양한 실험을 통해 NCF의 효용성 증명

Preliminaries

유저와 아이템 간의 관계를 명시적 혹은 암시적 정보를 이용한 행렬로 표현하고 MF로 예측할 수 있다. 자세한 내용은 다음 페이지를 참조 [Matrix Factorization Techniques for Recommender Systems](#))

The limitation of Matrix Factorization

본 논문의 저자는 내적과 같은 선형 모델은 유저와 서비스 간의 복잡한 관계를 표현하는데 한계가 있다고 얘기한다.



위의 그림으로 예시를 들어 선형 공간에서 내적이 갖는 한계를 설명하면 다음과 같다.

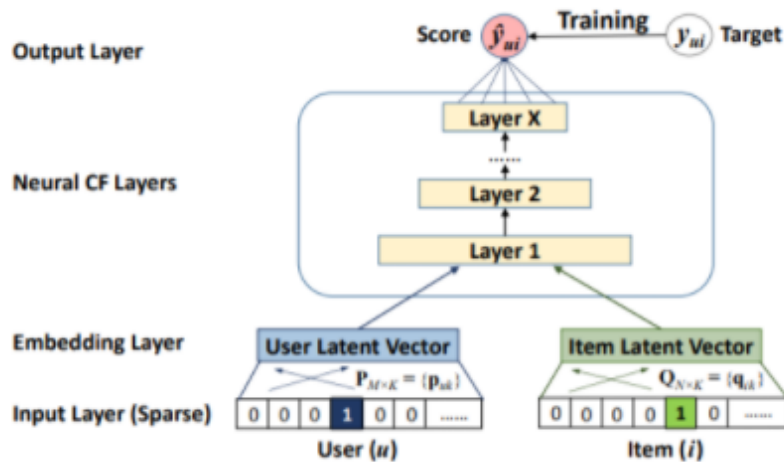
왼쪽은 유저와 서비스 간의 관계를 나타내는 행렬이며 오른쪽은 이를 내적한 결과, 즉 선형 공간에서의 벡터를 표현한 그림이다. 오른쪽 그림에서 알 수 있듯이 선형 공간에서는 유저 2와 3의 벡터가 가장 가까우며 유저 1과 유저 3의 벡터가 가장 멀다. 즉 유저 2와 3의 유사성이 높고 유저 1과 3의 유사성이 가장 낮다고 표현할 수 있다.

하지만 선형 모델의 문제점은 네 번째 유저가 등장하면서 나타난다. 유저 4는 유저 1과 가장 가까울 수 있고 2와 가장 멀 수 있지만 이를 2차원상의 선형 공간에서는 표현할 수 없다.


이런 한계는 유저와 서비스가 많아짐에 따라 더욱 극명하게 나타나게 된다. 특정 유저와 서비스의 관계를 벡터로 표현할 수 없는 것이다. 이러한 문제점은 기계학습을 이용하는 상황에서 다차원 공간의 특성을 파악해야 하는 문제에서 주로 발생하게 되는데, 딥러닝의 발전으로 인해 이러한 문제에 딥러닝을 적용하는 것이 가능해졌고, 논문의 저자도 심층 신경망을 활용하여 이를 보완하고 있다.

Neural Collaborative Filtering

아래의 그림은 논문의 저자가 주장한 NCF의 구조이며, 여기에 이용된 세부적인 구조는 다음과 같다.



- Input Layer
유저와 아이템 간의 원-핫 인코딩(one-hot encoding) 벡터 이용
- Embedding Layer



embedding layer란 입력 단계의 유저 희소 벡터를 밀집(dense) 벡터로 매핑하는 단계이다. 위의 그림은 이를 위한 하나의 예시이다. M차원의 유저 희소 벡터를 행렬 P를 이용하여 사영(projection)하여 K 차원의 밀집 벡터로 변환시키고 이를 유저 잠재 벡터(user latent vector)라고 부른다. 이와 같은 방식으로 서비스 잠재 벡터 또한 구한다.

- Neural CF Layer

이 단계는 유저 잠재 벡터와 서비스 잠재 벡터를 concatenate한 행렬을 새로운 입력으로 이용하여 심층 신경망을 구성하는 단계이다.

- Output Layer

이렇게 나온 가장 마지막 단계의 층의 결과를 logit 함수나 probit 함수를 이용하여 변환시키고 실제값 y와 추정치 y_{pred} 와 비교해서 얼마나 관련 있는지 나타내게 된다.